



南開大學
Nankai University

南 开 大 学

计算机学院、密码与网络空间安全学院
软件工程

Lab2: 需求分析

姓名：肖俊涛 学号：2313226

指导老师：刘健

2026 年 4 月 12 日

目录

一、 引言	1
(一) 编写目的	1
(二) 项目背景	1
二、 任务概述	3
(一) 任务目标	3
(二) 用户特点	3
(三) 假定与约束	4
1. 假定	4
2. 约束	4
三、 业务描述	6
(一) 系统总业务流程图及其描述	6
(二) 各个子业务流程图及其描述	7
1. 临床医学诊断人员	8
2. 基础医学实验人员	9
3. 生物信息学人员	10
4. 向量检索引擎研发人员	11
5. 公共生物数据库管理人员	12
6. 系统运维人员	13
四、 数据需求	15
(一) 数据需求描述	15
1. 用户信息数据	15
2. 细胞表达数据	16
3. 细胞元数据	16
4. 特征向量数据	17
5. 索引结构数据	17
6. 检索任务数据	18
(二) 数据逻辑关系描述	18
1. 一对多关系	19
2. 聚合关系	19
3. 多租户管理关系	19
4. 动态关联关系	19
5. 数据生命周期	19
(三) 数据流图	20
(四) 数据字典	26
1. 数据存储条目	26

2.	主要数据流	30
3.	外部实体	31
五、	功能需求	32
(一)	功能划分	32
(二)	功能描述	32
1.	M1 数据管理模块	33
2.	M2 索引构建模块	34
3.	M3 查询检索模块	35
4.	M4 可视化展示模块	37
5.	M5 用户信息模块	39
六、	性能/非功能需求	41
(一)	准确性	41
(二)	及时性	41
(三)	可扩充性	42
(四)	易用性	42
(五)	易维护性	42
(六)	标准性	43
(七)	先进性	43
七、	系统运行要求	44
(一)	硬件配置要求	44
(二)	软件配置要求	44

一、 引言

(一) 编写目的

本文档是针对“面向单细胞高维向量数据的近似最近邻 (ANN) 检索系统”所编写的软件需求分析报告。在软件工程生命周期中，需求分析是连接问题域与解域的核心桥梁。在开发涉及底层核心算法与特定业务领域的交叉学科系统时，我们总结出可能面临到的很多风险：

- 计算机背景的开发人员不理解单细胞数据的生物学特征（如高维极度稀疏、批次效应），而生物学用户可能无法理解 ANN 算法中“召回率与查询延迟的 Trade-off”。如果不沉淀清晰的需求文档，极易导致开发出的检索引擎在工程上完美，但在生物学实际应用中意义不大。
- 单细胞数据分析流水线极长（包含质控、降维、聚类、注释等）。如果不界定边界，用户可能会在开发中途不断要求加入数据预处理或下游分析功能，导致本系统从一个“高性能向量检索引擎”无限制膨胀为一个臃肿的“全链路分析平台”，拖垮项目进度。
- 面向高维向量的 ANN 索引极其消耗内存。在前期不以文档形式明确“千万级数据量下的硬件资源约束”和“查询响应时间标准”，可能导致后期系统在真实数据量下遭遇内存溢出或查询卡顿，造成架构级别的推倒重来。

基于上述风险，本文档致力于将模糊、碎片化的用户期望转化为清晰、无歧义的工程语言，具体编写目的包括：

- 作为开发团队、项目管理者以及最终用户之间的核心沟通契约，统一多方认知，消除不同角色之间的信息差和理解偏差。
- 明确本系统专注于特征提取后的“高维向量索引构建”与“多并发极速检索”，明确拒绝系统边界之外的底层生物测序下机数据清洗等功能。
- 将“系统要快”、“结果要准”这种主观描述，转化为具体的量化指标（比如在特定数据集上的 Top-100 查询，召回率必须 95%，P99 延迟 500ms）。
- 规范单细胞数据入库的格式规范，设计出用户端从上传数据到获取检索结果可视化的完整闭环流程。
- 为下一阶段的系统总体架构设计、向量数据库选型、前后端 API 接口定义以及微服务划分提供正确的基准依据，为系统测试阶段的黑盒测试、性能压测制定判定标准。

(二) 项目背景

单细胞测序技术已经由早期的“百级细胞”规模跃升至如今的“百万级乃至亿级细胞”通量，生物医学研究全面迈入单细胞分辨率的数字化时代。这种爆炸式增长的数据在计算层面带来了前所未有的挑战。在单细胞图谱的构建过程中，每一个细胞被映射为一个由数万个基因表达值构成的高维特征向量。当研究人员试图在海量参考数据集中为成千上万个未知细胞寻找“身份标

签”时，本质上是在进行**极高维度空间下的最近邻检索**。这种检索的计算成本正随着数据规模的扩大呈现非线性的剧烈增长，成为了制约生物信息学分析效率的瓶颈。

传统索引算法在高维空间中陷入了严重的维数灾难。在处理数万维的基因表达数据时，经典的 KD-Tree 或 Ball-Tree 等空间划分算法往往退化为接近线性扫描的复杂度，导致检索效率断崖式下跌。对于生物学家而言，面对千万级别的细胞基准库，如果单次查询耗时从秒级延长至分钟级甚至小时级，将直接导致交互式分析的停滞，使跨数据集的细胞比对、罕见细胞亚群的快速鉴定以及疾病关键靶点的实时追踪变得极度低效。计算效能的滞后会严重拖慢精准医疗和药物发现的迭代周期，原本珍贵的测序数据因“算不动、查不准”变成沉睡的数字资产。

针对这一痛点，本项目开发出**面向单细胞高维向量数据的近似最近邻（ANN）检索系统**。本系统通过深度定制针对单细胞数据分布特征优化的 ANN 算法，旨在打破精度与速度的互斥困境。我们致力于在保持较高的生物学召回率下**将海量数据的检索耗时压制在毫秒级量级**，在亿级细胞版图中精确定位特定病理状态下的细胞跃迁，为辅助临床诊断、加速新药靶点筛选提供关键的工程支撑。

二、任务概述

(一) 任务目标

本项目的核心任务是构建一个高性能、高可用、易扩展的单细胞向量数据检索平台。具体目标如下：

- **核心检索引擎建设：**深度集成支持高维稀疏/稠密向量的 ANN 索引构建与检索服务。系统需支持对千万级细胞向量数据进行快速入库和索引构建，并提供毫秒级的在线 Top-K 检索能力。
- **单细胞数据流水线集成：**支持标准化单细胞数据格式的解析与预处理，包括数据质控、标准化、PCA/高变基因降维，将其自动转化为检索引擎可识别的向量格式。
- **多租户与元数据管理：**具备强大的元数据过滤能力，实现“标量 + 向量”的混合查询。
- **索引更新与动态维护机制：**具备动态数据管理能力，设计高效的数据更新协议，支持在不关停检索服务的前提下，实现新样本向量的增量入库与索引实时挂载。
- **自定义检索模式：**支持用户一次性输入整个细胞簇的质心向量进行全局比对，并自动汇总检索结果的统计学特征。
- **直观的 Web 用户端：**支持用户上传待测细胞数据，实时返回高相似度的参考细胞，并在前端通过 UMAP/t-SNE 等低维映射技术进行查询结果的可视化联动展示。

(二) 用户特点

我们的系统面向交叉学科领域，用户群体在计算机技能和业务诉求上存在显著差异。在前期对实际情况的调研和走查后，我们将目标用户划分为以下六类：

1. **临床医学诊断人员：**通常在医院或大型医疗机构工作，对细胞层面的病理特征有深刻理解，但缺乏计算机编程背景。使用系统的主要目的是通过对比患者样本与标准参考图谱，快速识别异常细胞亚群或微小残留病灶。这类用户需要结果的可解释性和操作的极简性，我们的系统要能提供预定义的临床分析模板和直观的可视化诊断报告。
2. **基础医学实验人员：**系统数据的主要生产者 and 使用者，具备一定的生物信息学软件操作经验，倾向于使用图形化界面进行大批量的数据上传。核心诉求是系统的普适性，能够兼容多种测序平台产生的数据格式，并快速反馈查询细胞在全局版图中的定位，辅助其验证实验假说。
3. **生物信息学人员：**科研团队的数据中枢，精通 R 和 Python 等分析语言。这类用户关注检索的准确性、系统 API 的调用效率和数据交互的标准化。他们经常需要将本检索系统集成到复杂的自动化分析流程中，要求我们系统的 RESTful API 的稳定性、批量处理能力和异构数据的转换效率。需要提供技术文档，以便进行二次开发和个性化流水线定制。

4. **向量检索引擎研发人员:** 系统底层构建者, 关注 ANN 算法在单细胞数据下的性能瓶颈。单细胞数据具有极高的维度、严重的稀疏性以及显著的噪声特征, 他们需要评估不同索引结构的收敛速度与内存占用。这类用户需要系统具备底层监控日志, 能够实时反馈索引构建时间、单次查询延迟分布以及召回率的变化情况。
5. **公共生物数据库管理人员:** 负责维护和更新大规模的单细胞参考图谱。核心职责是确保入库数据的元数据完整性、本体术语的规范性以及数据版本的追溯性。这类用户关注系统对海量标量标签的过滤查询能力, 需要一套完善的后台管理界面, 用于监控数据增长趋势、审核用户提交的数据质量, 并执行全局索引的定期备份与版本维护。
6. **系统运维人员:** 硬件资源和软件架构的角度审视系统的运行状态。因为面向单细胞数据的 ANN 索引构建需要巨大的内存驻留和频繁的 I/O 调度, 运维人员的任务是确保检索服务的高可用性和弹性扩展能力, 要求系统具备完善的健康检查机制、自动故障转移策略, 支持容器化部署以应对突发的高并发检索需求。

(三) 假定与约束

我们对该系统做出一些假定和约束:

1. 假定

- **数据标准化:** 假定用户提供的输入数据已通过标准化的预处理流程, 包括空细胞过滤、双细胞去除以及线粒体基因比例质控。系统默认输入的向量是经过归一化和对数化后的表达矩阵或降维后的主成分空间。
- **嵌入模型稳定性:** 假定在进行向量提取时使用的深度学习模型在整个系统运行周期内是版本一致的。如果用户在不同时间上传同一细胞的不同向量表示, 系统假定这些向量位于相同的流形空间内, 不考虑因模型更新导致的向量分布偏移。
- **计算资源独占性:** 假定在索引构建和高并发检索期间, 服务器的关键资源 (如 L3 缓存、大页内存) 能够由本系统优先调度, 不考虑与其他重型计算作业 (如大规模测序比对) 长期共存时的极端资源抢占情况。
- **网络稳定性:** 假定终端用户使用支持 HTML5 协议及 WebGL 渲染的现代浏览器 (如 Chrome, Safari)。由于单细胞可视化涉及数万个前端 DOM 节点或 Canvas 像素渲染, 假定用户终端设备具备基础的图形加速能力。
- **生物学语义一致性:** 假定不同数据集之间的细胞类型标注遵循基本的本体论规范。系统在进行跨数据集检索和类型投票时, 假定同名的细胞类型在生物学意义上是高度相似的, 不考虑极端的批次效应导致的空间扭曲。

2. 约束

- **内存容量瓶颈:** 本系统核心索引必须在有限的服务器内存 (如 64GB 或 128GB) 下运行。对于千万级以上规模的数据, 必须采用向量量化或基于磁盘驱动的索引结构, 严禁在未做

压缩的情况下将超大规模原始高维浮点向量全量驻留内存。

- **检索精度红线：**系统在追求速度的同时，其近似最近邻检索的 Top-K 召回率在标准基准数据集上不得低于 95%。对于任何导致召回率低于 90% 的算法优化方案，均视为无效改进。
- **响应时间与并发：**在单机部署环境下，系统需支持至少 10 个并发查询请求，且单次查询的端到端响应时间不得超过 2 秒。对于后台索引构建任务，千万级数据的索引创建时间应控制在 4 小时以内。
- **技术栈与兼容性：**
 - **后端：**必须能够跨平台运行，底层核心计算模块需支持 C++ 17 以上标准以保证计算效能。
 - **前端：**必须采用前后端分离架构，前端框架需支持大数据的分级渲染，防止百万级散点图渲染导致浏览器崩溃。
 - **接口：**必须遵循 RESTful API 规范，且数据交换格式统一采用 JSON。
- **数据隐私与合规：**单细胞数据若来源于临床患者组织，可能涉及人类遗传资源数据及病患隐私。系统设计必须遵循《数据安全法》及相关医疗数据保护规范，系统日志和数据库中严禁明文存储患者身份等敏感脱敏前信息。
- **多租户：**系统必须实现物理或逻辑上的租户隔离。未经授权的用户严禁访问、检索或通过统计学手段推测其他用户的私有细胞向量数据。所有上传的敏感生物数据在磁盘存储时需进行加密处理。
- **扩展性：**系统的向量存储与检索模块必须具备水平扩容能力。当参考细胞库规模从百万级跃升至千万乃至亿级时，系统架构应支持通过增加数据分片节点的方式平滑扩展，而无需重构核心代码。
- **项目周期：**本项目为软件工程课程大作业，必须在规定 DDL 前完成开发、集成与测试。

三、 业务描述

(一) 系统总业务流程图及其描述




图 1: 系统总业务流程图

本系统的总业务流程旨在打造一个从单细胞数据上传、底层引擎处理到可视化结果输出的完整闭环。系统严格把控访问权限，不同类型的用户在进入系统后，将根据其角色被引导至专属的操作流中。

当我们的单细胞检索系统启动后，用户首先需要进入系统并进行登录操作。系统会进行身份校验：若登录成功，用户将直接跳转到系统的主功能页面；若登录失败，系统会提示错误并询问用户是否需要继续尝试登录，若选择继续则重新返回登录界面，若选择不继续则直接退出系统。

登录成功后，系统后台会根据数据库中存储的用户身份信息进行角色路由。我们的系统共设计了六类核心用户，他们分别被赋予了不同的核心功能路径：

1. **临床医学诊断人员**：通过系统为未知的病患细胞寻找“参考答案”，获取直观的诊断图表。
2. **基础医学实验人员**：大批量上传实验细胞，在全球视角下验证实验结果并观察细胞分布。
3. **生物信息学人员**：通过代码接口（API）与系统交互，进行高效率、自动化的批量数据检索。

4. **向量检索引擎研发人员**：深入系统底层，监控检索算法的运行速度和准确度，并进行参数调优。
5. **公共生物数据库管理人员**：负责维护系统背后的“参考字典”，上传并构建庞大的基准细胞索引库。
6. **系统运维人员**：站在全局视角，监控服务器的硬件资源消耗，保障系统不宕机。

所有用户在完成各自的业务操作后，均可安全退出系统，流程结束。

(二) 各个子业务流程图及其描述

为了让系统开发任务更加具象化，我们针对上述六类目标用户，分别设计了详细的子业务流程。

核心目标：临床医生通常不具备编程背景，他们的核心诉求是“查字典”。他们希望将患者的异常细胞数据输入系统，通过系统与庞大的健康或疾病参考细胞库进行比对，快速得出这些细胞属于什么类型、暗示着什么病理特征。

业务步骤：医生登录系统后，进入简洁的查询界面。首先，他们上传包含患者细胞特征的数据文件。随后，系统会在后台的“参考图谱库”中进行极速比对（近似最近邻检索）。比对完成后，系统不会给医生展示晦涩的代码，而是直接生成一份直观的可视化诊断报告。医生可以在报告中看到患者细胞与已知疾病细胞的相似度聚类图。医生阅读并保存这份报告后，即可退出系统。

核心目标：实验人员是系统的高频使用者。他们在做完单细胞测序实验后，需要知道自己培养出的细胞在整个生物学版图上处于什么位置，以此来验证他们的实验假说是否成立。

业务步骤：实验人员成功登录后，选择进入批量查询工作台。他们通常会一次性上传成千上万个实验细胞的数据集。系统接收到数据后，开始进行批量的特征检索。检索完成后，系统会在前端渲染出一幅包含数万个散点的高维降维图谱（UMAP/t-SNE）。实验人员可以在图谱上自由缩放、筛选，观察实验细胞（如标红的散点）是否如预期般落入了特定的细胞亚群中。完成观察和数据过滤后，他们可以将处理好的数据导出，随后退出系统。

1. 临床医学诊断人员




图 2: 临床医学诊断人员流程图

核心目标：临床医生通常不具备编程背景，他们希望将患者的异常细胞数据输入系统，通过系统与庞大的健康或疾病参考细胞库进行比对，快速得出这些细胞属于什么类型、暗示着什么病理特征。

业务步骤：医生登录系统后，进入查询界面。首先，他们上传包含患者细胞特征的数据文件。随后，系统会在后台的数据库中利用近似最近邻检索进行比对。比对完成后，系统直接生成一份可视化诊断报告。医生可以在报告中看到患者细胞与已知疾病细胞的相似度聚类图。医生阅读并保存这份报告后，即可退出系统。

2. 基础医学实验人员




图 3: 基础医学人员流程图

核心目标：实验人员对系统的使用需求较高。他们在做完单细胞测序实验后，需要知道培养出的细胞在生物学层面的位置，以此来验证他们的实验假说是否成立。

业务步骤：实验人员成功登录后，选择进入批量查询工作台。他们通常会一次性上传大量实验细胞的数据集。系统接收到数据后，开始进行批量的特征检索。检索完成后，系统会在前端渲染出高维降维图谱（UMAP/t-SNE）。实验人员可以在图谱上自由缩放、筛选，观察实验细胞是否属于特定的细胞亚群。完成观察和数据过滤后，他们可以将处理好的数据导出，随后退出系统。

3. 生物信息学人员




图 4: 生物信息学人员流程图

核心目标：这类用户是专业的计算机与生物交叉人才。他们不需要花哨的图形界面，而是需要稳定、高速的系统接口（API），以便将本系统的检索能力像“插件”一样无缝接入到他们自己编写的复杂数据分析流水线中。

业务步骤：生信人员登录系统后台，首先申请或获取一个专属的 API 开发者密钥（Token）。随后，他们离开可视化界面，在自己的编程环境（如 Python 脚本）中，配置好需要的检索参数并发起代码请求。系统后端接收到指令后，在服务器内部飞速执行数学计算，并将匹配到的细胞

数据以结构化文本（JSON 格式）直接返回。生信人员确认数据接收无误后，流程结束。

4. 向量检索引擎研发人员




图 5: 向量检索引擎研发人员流程图

核心目标：作为系统的底层“工程师”，他们不关心细胞长什么样，只关心系统查得“准不准”和“快不快”。他们的目标是监控底层算法的性能，并突破高维数据带来的“维数灾难”瓶颈。

业务步骤：研发人员登录后，直接进入系统的性能监控看板。他们会向系统发送模拟的极限压力测试请求，以此来观察服务器的反应。系统会实时反馈出单次查询耗费了多少毫秒、算法找对正确细胞的概率（召回率）是多少。如果发现速度变慢或准确率下降，研发人员会在后台调整

底层算法的超参数（例如修改索引结构的层级）。确认性能指标回升并趋于稳定后，保存配置并退出系统。

5. 公共生物数据库管理人员




图 6: 公共生物数据库管理人员流程图

核心目标：他们是系统数据的“大管家”。单细胞数据是不断更新的，管理人员需要定期将全球最新发表的权威细胞数据洗列、整理，并纳入本系统的后台中，让所有人都能搜到最新的结果。

业务步骤：管理员登录数据管理中心，选择上传最新规模的参考细胞矩阵文件。因为数据极

其庞大，系统首先会进行自动化的格式校验和数据清洗。校验合格后，管理员下达“构建索引”的指令。此时，系统后台开始进行繁重的数学运算，为这些新数据建立方便检索的“目录”（ANN索引）。构建完成后，管理员对索引进行质量审核，确认无误后将其挂载到线上发布，供全系统用户使用，最后退出系统。

6. 系统运维人员




图 7: 系统运维人员流程图

核心目标：保障整个软件系统的物理环境和网络环境稳定运行。面对海量数据的频繁读取，他们需要防止服务器内存撑爆或系统崩溃。

业务步骤：运维人员登录硬件控制台，面前展示的是服务器 CPU、内存使用率和网络 I/O 的实时波动图。他们会例行检查系统的健康状态。如果发现某段时间内检索请求过高导致内存告警，运维人员会立即启动自动故障转移或弹性扩容策略，增加计算资源。同时，他们还会定期执行系统底层日志的备份与清理工作。确认各项硬件指标均在安全绿线内后，结束巡检并退出系统。

四、 数据需求

(一) 数据需求描述

本系统涉及的数据流涵盖了从原始生物学表达矩阵到高性能二进制索引文件的全生命周期。由于单细胞数据具有“高维度”与“极度稀疏”的特性，且检索过程涉及复杂的向量空间变换，系统需要处理多样化的数据类型以保证检索的精确度与系统的稳定性。

根据系统功能需求，我们将数据划分为以下 6 类主要类型，具体描述见下表：

表 1: 系统数据需求分类表

编号	数据类型名称	数据描述与组成内容	存储特性
1	用户信息数据	包含唯一标识 ID、加密密码散列值、用户角色（临床/生信/运维等）、所属机构及资源配额信息。	永久存储、高安全性
2	细胞表达数据	原始单细胞基因表达矩阵文件路径，包含基因序列列表、细胞总数、数据来源及稀疏度统计信息。	大规模、只读存储
3	细胞元数据	对应每个细胞的生物学标签，如组织来源、供体信息、细胞类型及支持动态扩展的 JSONB 格式自定义字段。	关系型存储、支持过滤
4	特征向量数据	经过降维处理后的稠密向量数组 (Blob)，包含向量维度、使用的降维算法及预处理归一化参数。	批量读取、高性能 IO
5	索引结构数据	ANN 算法生成的二进制索引文件，记录距离度量准则、算法超参数（如 <i>M</i> 、 <i>ef_construction</i> ）及构建状态。	内存驻留、支持热加载
6	检索任务数据	记录单次查询向量、检索参数 (<i>Top_K</i> 等)、执行耗时、匹配结果 ID 列表及可视化 UMAP 坐标。	任务级存储、定期清理

1. 用户信息数据

本数据项用于维护系统的访问控制与多租户隔离。

表 2: 用户信息表 (users) 字段定义

字段名	数据类型	约束	说明
user_id	BIGINT UNSIGNED	PRIMARY KEY, AUTO_INCREMENT	唯一用户标识符, 采用无符号大整型以保证海量用户扩展性。
username	VARCHAR(64)	NOT NULL, UNIQUE	用户登录名, 设置唯一索引, 长度限制为 64 字符。
password_hash	VARCHAR(255)	NOT NULL	存储高强度哈希散列值 (如 Argon2), 255 位宽以兼容各算法。
role_type	ENUM(...)	NOT NULL	权限角色映射: Guest, Researcher, Admin 。
institution	VARCHAR(128)	NOT NULL	用户关联的机构或实验室全称, 支持多租户隔离查询。
storage_quota	DECIMAL(10, 2)	DEFAULT 0.00	个人私有云盘配额 (GB), 使用精密浮点数避免精度误差。
created_at	TIMESTAMP	DEFAULT CURRENT_TIMESTAMP	记录账户创建时间, 由数据库系统自动生成。

2. 细胞表达数据

由于单细胞表达矩阵具有极高的维度和稀疏性, 数据库中主要存储文件索引信息。

表 3: 细胞表达数据表 (expression_metadata) 字段定义

字段名	数据类型	约束	说明
dataset_id	BIGINT UNSIGNED	FOREIGN KEY	关联数据集唯一标识, 建立外键约束。
matrix_file_path	VARCHAR(512)	NOT NULL	稀疏矩阵文件 (.h5ad/.mtx) 的绝对物理存储路径。
gene_list	LONGTEXT	NOT NULL	以 JSON 格式存储的基因序列, 用于不同批次的特征对齐。
cell_count	INT UNSIGNED	NOT NULL	数据集包含的细胞样本总数。
sparsity_ratio	DECIMAL(5, 4)	DEFAULT 0.0000	矩阵稀疏度 (0-1 之间), 用于读取性能预估。
data_source	VARCHAR(128)	DEFAULT NULL	原始数据来源说明, 如 NCBI GEO 的接入号。

3. 细胞元数据

元数据存储每个细胞的生物学标签, 支持动态扩展以适应差异化需求。

表 4: 细胞元数据表 (cell_metadata) 字段定义

字段名	数据类型	约束	说明
cell_id	BIGINT UNSIGNED	PRIMARY KEY	唯一细胞编号, 作为本表的主键。
dataset_id	BIGINT UNSIGNED	NOT NULL	所属数据集编号, 用于数据层级的快速筛选。
tissue_type	VARCHAR(64)	NOT NULL	组织来源 (如 Lung, PBMC), 支持分类索引。
donor_id	VARCHAR(64)	NOT NULL	供体唯一标识, 用于多样本实验的个体区分。
cell_type_label	VARCHAR(64)	DEFAULT 'Unknown'	专家标注的细胞类型 (如 T-cell, B-cell)。
sequencing_platform	VARCHAR(64)	NOT NULL	测序平台信息 (如 10x Genomics, Smart-seq2)。
extended_info	JSON	DEFAULT NULL	实验室个性化动态字段, 如药物浓度、批次信息等。

4. 特征向量数据

这是进入 ANN 索引的直接输入, 通常是降维后的稠密向量。

表 5: 特征向量数据表 (cell_vectors) 字段定义

字段名	数据类型	约束	说明
vector_id	BIGINT UNSIGNED	PRIMARY KEY	向量唯一标识。
cell_id	BIGINT UNSIGNED	UNIQUE, FOREIGN KEY	关联物理细胞 ID, 确保一细胞对应一特征向量。
embedding_data	MEDIUMBLOB	NOT NULL	存储 32 位浮点数数组 (如 128 维稠密向量二进制)。
dimension	SMALLINT UNSIGNED	NOT NULL	向量维度 (如 128, 256, 512)。
reduction_method	VARCHAR(32)	NOT NULL	降维算法 (如 PCA, VAE, scVI) 名称。
normalization_params	JSON	DEFAULT NULL	归一化缩放因子, 用于跨数据集查询时的预处理。

5. 索引结构数据

记录 ANN 算法生成的索引实体及其超参数。

表 6: 索引结构数据表 (ann_indices) 字段定义

字段名	数据类型	约束	说明
index_id	BIGINT UNSIGNED	PRIMARY KEY	索引唯一标识符。
index_type	VARCHAR(32)	NOT NULL	算法类型, 如 HNSW, IVF_PQ, ScaNN 等。
index_file_path	VARCHAR(512)	NOT NULL	索引二进制文件在服务器上的物理存储路径。
metric_type	ENUM(...)	NOT NULL	距离度量标准, 包括 L2 (欧式距离), Cosine, IP (内积)。
hyper_params	JSON	NOT NULL	存储构建参数 (如 <i>M, ef_construction, nlist</i>) , 便于实验追溯。
memory_usage	BIGINT UNSIGNED	DEFAULT 0	索引加载至内存后的预计占用大小 (字节), 用于调度参考。
build_status	ENUM(...)	DEFAULT 'Building'	索引构建状态: Building , Ready , Error 。

6. 检索任务数据

记录用户的检索行为历史与生成的中间分析结果。

表 7: 检索任务数据表 (search_tasks) 字段定义

字段名	数据类型	约束	说明
task_id	BIGINT UNSIGNED	PRIMARY KEY	检索任务唯一流水号。
user_id	BIGINT UNSIGNED	NOT NULL	关联发起检索的用户 ID (外键)。
query_vector	MEDIUMBLOB	NOT NULL	查询向量快照, 用于任务复现或审计。
search_params	JSON	DEFAULT NULL	检索动态参数 (如 <i>ef_search, k</i> 值等)。
result_json	JSON	DEFAULT NULL	检索出的 Top-K 细胞 ID 序列及其对应的距离分值。
visualization_coords	JSON	DEFAULT NULL	存储该任务生成的 UMAP 或 t-SNE 降维二维坐标。
execution_time	INT UNSIGNED	DEFAULT 0	任务执行耗时 (毫秒)。
task_status	ENUM(...)	DEFAULT 'Pending'	任务生命周期: Pending , Running , Completed , Failed 。

(二) 数据逻辑关系描述

我们可以将上面所有数据划分为三个核心层: **管理层**、**数据层**以及**业务层**。下面是逻辑关系说明:

1. 一对多关系

细胞表达数据 (2) → 细胞元数据 (3) 特征向量数据 (4): 一个原始的表达矩阵包含成千上万个细胞。每一个细胞在数据库中对应唯一的细胞元数据记录和至少一个特征向量数据记录。

细胞元数据 (3) ↔ 特征向量数据 (4): 在特定的降维算法下, 两者是一对一关系。它们通过 cell_id 关联。元数据负责描述它是哪种细胞, 特征向量说明它在向量空间哪里。

2. 聚合关系

特征向量数据 (4) → 索引结构数据 (5): 这是一个多对一或多对多关系。系统会选取大量细胞的特征向量作为训练集和存储集, 构建出一个 ANN 索引。一个索引结构包含了数百万个细胞向量的拓扑关系。反之, 同一批特征向量也可以根据不同的距离度量 (如欧氏距离或余弦相似度) 构建出多个不同的索引结构。

3. 多租户管理关系

用户信息数据 (1) → 所有其他数据: 用户信息与细胞表达数据、索引结构数据、检索任务数据均构成一对多关系。系统通过 user_id 实现物理或逻辑隔离: 用户 A 只能看到并检索自己上传的数据集生成的索引, 除非该数据集被标记为公共数据库。

4. 动态关联关系

检索任务数据 (6) 应该位于逻辑联动的中心:

- **关联用户:** 由唯一的 user_id 发起。
- **关联索引:** 任务必须指定针对哪个 index_id 进行搜索。
- **关联结果:** 检索完成后, 任务记录中的 result_json 会存储命中细胞的 cell_id 列表。
- **回溯元数据:** 系统最终通过 cell_id 从细胞元数据 (3) 中提取生物学标签, 返回给用户

5. 数据生命周期

- **生产链路:** 用户 (1) → 上传表达数据 (2) → 提取特征向量 (4) → 构建索引 (5)。
- **消费链路:** 用户 (1) → 创建检索任务 (6) → 调用索引 (5) → 匹配向量 (4) → 获取元数据标签 (3) → 展示结果。

(三) 数据流图




图 8: 0 层图（上下文图）

图 8 为系统的 0 层数据流图，即上下文图，用于描述单细胞 ANN 检索系统与外部环境的整体交互关系。图中将整个系统抽象为一个黑盒，仅展示系统与三类外部实体之间的数据流：外部数据源 (NCBI GEO 或用户直接上传) 向系统提供 h5ad/.mtx 格式的数据集文件；用户 (Web 前端) 通过上传请求、检索请求及交互操作与系统双向通信，并接收检索结果、UMAP 图及 PDF 报告；API 客户端 (Python/R) 通过携带 API Token 的 POST /search 请求发起检索，系统以 JSON 格式返回 Top-K 结果。

该图的核心价值在于划定系统边界：认证信息 (用户名/密码/Token) 流入系统底部，可视化结果从系统流出至用户，清晰体现了系统对外暴露的三个接入点 (Web 前端、程序化 API 及外部数据导入)，为后续分层细化提供了整体框架。

图 9 将系统内部展开为六个主要处理过程 (P1P6) 和六个数据存储 (D1D6)，完整呈现系统的总体数据流结构。P6 (用户认证与权限控制) 位于顶部，负责处理用户注册/登录并向 P4 传递鉴权结果；P1 (数据导入与预处理) 接收外部数据源和用户上传的数据集，将解析后的信息分别写入 D2 (数据集信息) 和 D3 (细胞信息)；P2 (向量生成与降维) 读取 D2 和 D3 后将生成的嵌入向量写入 D4；P3 (索引构建与管理) 从 D4 读取向量并将构建好的 ANN 索引写入 D5；P4 (相似性检索与执行) 同时读取 D4 和 D5 完成检索并将任务记录写入 D6；P5 (可视化与报告导出) 读取 D6 和 D3 后将可视化结果返回用户。

各处理过程对应后续子图中的功能模块 (M1M5)，数据存储之间通过跨行数据流实现级联：从原始数据 (D2/D3) → 向量 (D4) → 索引 (D5) → 检索结果 (D6) 的完整流水线贯穿整张图，直观展示了系统的核心处理链路。

软件工程期末大作业：系统总体数据流图 (Level-1)




图 9: 1 层图 (系统总体数据流图)

图 10 细化了 M1 模块 (对应 1 层图中的 P1 和 P2), 展示数据从原始文件到特征向量的完整预处理流程, 共包含四个子过程。F1.1 (数据导入与上传) 接收来自外部数据源的.h5ad/.mtx/.csv 文件及用户上传请求, 解析后将数据集基本信息写入 D2, 同时将原始矩阵传递给 F1.2; F1.2 (格式校验) 对矩阵进行质控, 补充 cell_count 和 sparsity_ratio 等统计量至 D2, 并将细胞行级信息 (cell_id、测序平台) 写入 D3, 如校验失败则向用户返回错误提示; F1.3 (数据预处理) 支持 PCA、VAE、scVI 等降维方法, 将生成的嵌入向量 (embedding_data) 及相关参数写入 D4; F1.4 (数据查看与删除) 将组织类型、细胞类型标签等用户补充的元数据回写至 D3。

该子图体现了系统对多种单细胞数据格式的兼容能力, 以及从 I/O 密集型解析到计算密集型特征提取的处理层次, 为后续索引构建提供高质量的向量输入。

软件工程期末大作业：M1子图——数据导入与预处理




图 10: M1 子图——数据导入与预处理

图 11 描述了 ANN 索引的构建与状态管理全过程，包含四个子过程。F2.1（索引类型与参数配置）接收用户配置的 `index_type`（HNSW/IVF_PQ/ScaNN）、距离度量类型（L2/Cosine/IP）及超参数（如 `M`、`ef_construction`、`nlist`），将配置参数下传至 F2.2；F2.2（索引构建）从 D4 读取所有细胞的 `embedding_data`，调用 ANN 库完成内存级索引构建，构建过程中 `build_status` 实时置为 `Building`；F2.3（索引保存与加载）将构建完成的索引序列化至磁盘，写入 D5 中的 `index_file_path`，并对其进行 Top-K 召回率验证（要求 Top-100 精度 95%）；F2.4（索引状态监控与版本管理）根据验证结果将 D5 中的 `build_status` 更新为 `Ready` 或 `Error`，并通知用户最终状态。

该模块是系统检索性能的核心保障，通过参数化配置支持不同规模数据集下索引类型与精度-速度的灵活权衡。

软件工程期末大作业：M2子图——ANN索引构建与管理




图 11: M2 子图——ANN 索引构建与管理

图 12 展示了检索请求从接入到返回结果的完整执行链路，共六个子过程。F3.1（查询输入）从 D4 读取归一化参数，对用户或 API 客户端提交的查询向量进行预处理，确保其与索引空间的度量标准一致；F3.2（检索参数配置）接收用户指定的 Top-K 值、ef_search 参数及过滤条件，将完整的检索配置传递给 F3.3；F3.3（精确最近邻检索）加载 D5 中的索引文件，在近似邻居搜索阶段返回 Top-K×2 的候选集，以保留精排空间；F3.4（近似最近邻检索）从 D4 读取候选集中各细胞的原始向量，进行精确距离计算并重排序，得到最终 Top-K 结果；F3.5（批量检索）将 task_id、result_json 及 UMAP 可视化坐标写入 D6，同时向 Web 用户返回任务预览；F3.6（程序化调用接口）将结果以 JSON 格式和执行时间返回给 API 客户端，支持 POST /search 及

POST /batch-search 两种接入方式。

该子图体现了“ANN 粗筛 + 精确重排”的两阶段检索策略，在保证召回率的同时通过异步任务机制（D6 状态追踪）支持长时检索的可观测性。




图 12: M3 子图——ANN 检索与任务执行

图 13 描述了检索结果从数据存储到用户前端的展示与导出流程，包含四个子过程。F4.1 (Top-K 检索结果列表展示) 从 D6 读取检索结果 (result_json、Top-K 细胞 ID)，并向 D3 查询对应细胞的 cell_type_label、tissue_type、donor_id 等注释信息，将富化后的结果列表推送给用户；F4.2 (UMAP/t-SNE 降维散点图可视化) 从 D6 读取预计算的可视化坐标 (UMAP_x/UMAP_y)，借助 WebGL 渲染引擎生成高性能散点图，将 Top-K 命中细胞在低维空间中高亮展示；F4.3 (性能指标展示) 接收用户的缩放、筛选、悬停、选择等交互操作，动态更新 WebGL/DOM 渲染，实现大规模散点图的流畅交互；F4.4 (诊断报告导出) 聚合 F4.1 的 Top-K 结果列表和 F4.2 的 UMAP 图，生成结构化 PDF 报告供用户下载。

该模块将数值检索结果转化为可读的生物学语义视图，UMAP 的低维投影与 Top-K 列表的并排呈现，使研究人员能够直观判断检索到的细胞在表达空间中的分布规律。




图 13: M4 子图——检索结果可视化与导出

图 14 展示了系统的用户安全体系，包含四个子过程，贯穿注册、认证、鉴权与配额全生命周期。F5.1(用户注册)接收用户提交的 username、password 及 role_type(Guest/Researcher/Admin)，将加密后的 password_hash、自动分配的 user_id 及存储配额写入 D1；F5.2 (用户登录与身份验证) 从 D1 读取 password_hash 和 role_type 进行凭据比对，验证成功后签发有效期为 3 天的 Token 返回给用户；F5.3 (角色权限控制) 作为所有功能模块的统一门卫，验证 Web 端用户提交的 Token 或 API 客户端 HTTP Header 中的 API Token，从 D1 读取角色信息后决定是否放行——无权限操作返回 403 Forbidden；F5.4 (用户管理) 在操作完成后更新 D1 中的 storage_quota 消耗记录。

该子图体现了系统对多角色差异化访问控制的设计，集中式的 Token 验证与配额管理确保了数据安全性与资源使用的可追溯性。



图 14: M5 子图——用户管理、认证与权限控制

(四) 数据字典

本数据字典与数据流图 (DFD) 配套，对系统中所有数据存储、主要数据流及外部实体进行规范化定义。字段约束符号说明如下：

符号	含义
[PK]	主键 (Primary Key)
[FK]	外键 (Foreign Key)
[NN]	非空 (NOT NULL)
[IDX]	建有索引
=	由以下成分组成
+	顺序连接
{ }	重复 (一个或多个)
[]	选择 (其中之一)
()	可选项

1. 数据存储条目

D1 用户信息

描述：存储注册用户的身份信息、角色类型及存储配额，由 M5 维护，供 P6 认证与权限校验读

写。**关联处理：**F5.1 / F5.2 / F5.3 / F5.4。**存储介质：**关系型数据库（PostgreSQL / SQLite）。

结构定义：

用户信息 = user_id + username + password_hash + role_type + (institution) + storage_quota + created_at

字段名	约束	类型/范围	说明
user_id	[PK][NN]	UUID / 自增整数	用户唯一标识符，系统自动生成
username	[NN][IDX]	VARCHAR(64)	登录用户名，全局唯一
password_hash	[NN]	CHAR(64)	密码哈希摘要（bcrypt / SHA-256），禁止明文存储
role_type	[NN]	ENUM	取值：Guest、Researcher、Admin
institution	可选	VARCHAR(128)	所属机构名称
storage_quota	[NN]	FLOAT (GB)	用户可用存储上限，默认值由角色决定； ≥ 0
created_at	[NN]	TIMESTAMP	账户创建时间，系统自动填写

完整性约束：username 全局唯一；role_type 仅限三个枚举值；storage_quota ≥ 0；password_hash 不可通过普通接口读取明文。

D2 数据集信息

描述：存储导入数据集的元信息，包括文件路径、基因列表、细胞数量及数据来源，由 F1.1/F1.2 写入，P2 读取。**存储介质：**关系型数据库 + 文件系统（矩阵文件另存）。

结构定义：

数据集信息 = dataset_id + matrix_file_path + (gene_list) + cell_count + sparsity_ratio + (data_source)

字段名	约束	类型/范围	说明
dataset_id	[PK][NN]	UUID / 自增整数	数据集唯一标识符
matrix_file_path	[NN]	VARCHAR(512)	矩阵文件服务器绝对路径，支持 .h5ad、.mtx
gene_list	可选	JSON / Text	基因特征名称列表
cell_count	[NN]	INTEGER	细胞总数，由 F1.2 写入；> 0
sparsity_ratio	[NN]	FLOAT [0, 1]	矩阵稀疏度（零元素比例），由 F1.2 计算
data_source	可选	VARCHAR(256)	数据来源，如 NCBI GEO、用户上传

D3 细胞信息

描述：存储每个细胞的生物学元数据，由 F1.2/F1.4 写入，M4 可视化模块读取用于结果富化。数据量可达 $10^5 \sim 10^7$ 条。**存储介质：**关系型数据库（含 JSONB 扩展字段）。

结构定义：

细胞信息 = cell_id + dataset_id + (tissue_type) + (donor_id) + (cell_type_label) + (sequencing_platform) + (extended_info)

字段名	约束	类型/范围	说明
cell_id	[PK][NN]	UUID / 自增整数	细胞唯一标识符
dataset_id	[FK][NN][IDX]同 D2		所属数据集，外键引用 D2.dataset_id
tissue_type	可选	VARCHAR(64)	组织来源，如 Lung、Spleen、PBMC
donor_id	可选	VARCHAR(64)	捐献者标识
cell_type_label	可选	VARCHAR(128)	细胞类型注释，如 T-cell、B-cell、Macrophage
sequencing_platform	可选	VARCHAR(64)	测序平台，如 10x Genomics、Smart-seq2
extended_info	可选	JSONB	扩展字段，存储其他可变元数据

完整性约束：dataset_id 须在 D2 中存在；extended_info 须为合法 JSON。

D4 向量表示

描述：存储每个细胞经降维后的特征向量，是 ANN 索引构建和相似性检索的核心数据，由 F1.3 写入，M2/M3 读取。**存储介质：**向量数据库或关系型数据库（Binary 列）+ 文件系统。

结构定义：

向量表示 = vector_id + cell_id + embedding_data + dimension + reduction_method + (normalization_params)

字段名	约束	类型/范围	说明
vector_id	[PK][NN]	UUID / 自增整数	向量记录唯一标识符
cell_id	[FK][NN][IDX]同 D3		对应细胞，外键引用 D3.cell_id
embedding_data	[NN]	Blob / Binary	32 位浮点向量，维度典型值 128~2048
dimension	[NN]	INTEGER	向量维数； ≥ 1 ，须与 embedding_data 长度一致
reduction_method	[NN]	VARCHAR(16)	降维算法，取值 PCA、VAE、scVI 之一

字段名	约束	类型/范围	说明
normalization_params	可选	JSON	归一化参数（均值、标准差等），供检索时查询向量对齐

D5 ANN 索引

描述：存储构建完成的近似最近邻索引的元信息及文件路径，索引本体序列化于高速 SSD，由 M2 写入，M3 加载使用。**存储介质：**关系型数据库（元信息）+ SSD（索引文件，可达 GB 级）。

结构定义：

ANN 索引 = index_id + index_type + index_file_path + metric_type + hyper_params + (memory_usage) + build_status

字段名	约束	类型/范围	说明
index_id	[PK][NN]	UUID / 自增整数	索引记录唯一标识符
index_type	[NN]	VARCHAR(16)	索引算法，取值 HNSW、IVF_PQ、ScaNN 之一
index_file_path	[NN]	VARCHAR(512)	索引序列化文件的服务器绝对路径
metric_type	[NN]	VARCHAR(16)	距离度量，取值 L2（欧氏）、Cosine（余弦）、IP（内积）之一
hyper_params	[NN]	JSON	超参数；HNSW 典型：M=32，ef_construction=200；IVF 典型：nlist=1024
memory_usage	可选	FLOAT（GB）	索引加载至内存后的占用量估算
build_status	[NN]	ENUM	取值 Building、Ready、Error 之一

完整性约束：build_status = Ready 时 index_file_path 所指文件须存在；Top-100 召回率验证须 ≥ 95% 方可置 Ready；hyper_params 须含算法必需键。

D6 检索任务

描述：记录每次检索请求的完整信息，包括查询向量、检索参数、Top-K 结果及可视化坐标，由 M3 写入，M4 读取。**存储介质：**关系型数据库（含 JSONB 列），建议定期归档历史任务。

结构定义：

检索任务 = task_id + user_id + query_vector + search_params + (result_json) + (visualization_coords) + (execution_time) + task_status

字段名	约束	类型/范围	说明
task_id	[PK][NN]	UUID / 自增整数	检索任务唯一标识符
user_id	[FK][NN][IDX]同 D1		发起检索的用户，外键引用 D1.user_id
query_vector	[NN]	Blob / Binary	查询细胞的嵌入向量，维度须与目标索引一致
search_params	[NN]	JSON	检索参数，含 top_k (1~1000)、ef_search、过滤条件
result_json	可选	JSONB	Top-K 检索结果，含每条命中的 cell_id 及距离分数
visualization_coords	可选	JSONB	可视化坐标，格式 {cell_id: [UMAP_x, UMAP_y]}
execution_time	可选	FLOAT (ms)	检索耗时；设计目标 P99 $\leq$ 500 ms
task_status	[NN]	ENUM	取值 Pending、Running、Completed、Failed 之一

完整性约束：task_status = Completed 时 result_json 不得为空；search_params 须含 top_k 且 $1 \leq \text{top_k} \leq 1000$ ；execution_time ≥ 0 。

2. 主要数据流

数据流名	来源	去向	主要成分	备注
数据集文件	外部数据源 / 用户	P1	矩阵文件 (.h5ad/.mtx/.csv) + 元信息	支持多格式
检索请求	用户 / API 客户端	P4	query_vector + top_k + ef_search + 过滤条件 + Token	POST /search
Top-K 检索结果	P4	用户 / API 客户端 / D6	task_id + {cell_id + 距离分数 + 细胞注释} + execution_time	JSON 格式返回
认证令牌	P6 (F5.2)	用户 / API 客户端	token_value + user_id + role_type + expire_at	有效期 3 天
索引构建配置	用户	P3	index_type + metric_type + hyper_params	写入 D5

数据流名	来源	去向	主要成分	备注
构建状态通知	P3 (F2.4)	用户	<code>build_status</code> (Building / Ready / Error)	异步推送
可视化结果	P5	用户	Top-K 结果列表 + UMAP 散点图 + PDF 报告	WebGL 渲染

3. 外部实体

实体名	别名	输入系统的数据	从系统接收的数据
外部数据源	NCBI GEO / 文件上传	数据集文件 (.h5ad/.mtx/.csv)	无
用户	Web 前端	上传请求、检索请求、交互 操作、登录凭据、索引配置、 元数据补充	检索结果、UMAP 图、 PDF 报告、Token、构建状 态、校验报告
API 客户端	Python / R 程 序	POST /search (含 API Token)、POST /batch-search	Top-K 结果 (JSON)、 <code>execution_time</code>

五、 功能需求

(一) 功能划分

本系统依据项目任务目标与用户业务需求，划分为五大核心功能模块。各模块既相互独立、职责清晰，又通过数据接口协同运作，共同构成完整的单细胞 ANN 检索平台。功能模块总览如下表所示：

表 16: 模块功能说明

模块编号	模块名称	核心职责	主要服务用户
M1	数据管理模块	单细胞数据的导入、读取、格式校验与基础预处理	基础医学实验人员、公共生物数据库管理人员
M2	索引构建模块	ANN 索引的构建、保存与加载，为高效查询提供支持	公共生物数据库管理人员、向量检索引擎研发人员
M3	查询检索模块	接收查询输入，执行精确/近似检索，返回 top-k 结果	全部用户
M4	可视化展示模块	将检索结果以直观、交互式的形式展示给用户	临床医学诊断人员、基础医学实验人员
M5	用户信息模块	用户注册登录、身份验证、权限管理与用户管理	全部用户

各模块的层次结构与子功能划分如图15所示。



图 15: 子功能划分

(二) 功能描述

本节对上述五大模块中的各功能点进行详细描述，格式参照国标软件需求规格说明书规范，每项功能均包含：功能编号、功能名称、功能描述、输入、处理逻辑、输出，以及与其他模块的关联关系。

1. M1 数据管理模块

数据管理模块是整个单细胞 ANN 检索系统数据生命周期的起点，负责单细胞数据的导入、读取和组织管理。系统将单细胞样本表示为高维向量，并对输入数据进行格式校验和基础预处理，以保证后续检索流程能够正常进行。

F1.1 数据导入与上传

数据导入与上传功能是用户将本地单细胞测序数据接入系统的唯一入口。系统提供基于 Web 界面的文件上传通道，支持单细胞领域主流数据格式，包括.h5ad (AnnData 格式)、.mtx (稀疏矩阵格式) 以及.csv (逗号分隔值格式)。

用户在上传文件时，还需同步填写数据集的描述信息，包括数据来源说明（如 NCBI GEO 编号）、测序平台（如 10x Genomics、Smart-seq2）及数据集的基本统计量。系统接收到文件流后，将其写入服务器存储，并将文件的物理路径 (matrix_file_path)、数据来源 (data_source)、细胞总数 (cell_count) 等元信息持久化记录至数据库，同时为该数据集生成唯一标识 (dataset_id) 供后续流程引用。

考虑到单细胞数据文件体积通常较大，本功能支持文件分块上传与断点续传机制，并在前端实时展示上传进度，避免因网络波动导致的上传失败。上传完成后，系统自动触发 F1.2 格式校验流程，进入下一阶段处理。

F1.2 数据格式校验

数据格式校验功能是保障后续检索质量的前置屏障。原始单细胞测序数据往往包含大量低质量细胞（如空液滴、双细胞、损坏细胞），若不加筛选直接进入索引，将严重干扰检索结果的生物学可信度，因此本功能设计了自动化的两阶段校验流程。

第一阶段为格式合法性检验，系统对上传文件的字段完整性、数据类型一致性和矩阵维度进行逐项检查，确保文件结构符合系统要求，字段不缺失、数据类型正确、基因列表与细胞编号无重复。

第二阶段为生物学质控，系统依次执行以下操作：首先过滤空细胞，将总计数为零或基因检出数极少的细胞视为无效数据予以剔除；其次执行双细胞检测，识别并标注可能由两个细胞误封装至同一液滴而产生的双细胞样本；最后计算每个细胞的线粒体基因表达比例，超过质控阈值的细胞视为受损细胞，予以过滤。质控完成后，系统计算并记录矩阵稀疏度 (sparsity_ratio)，用于评估后续处理的 I/O 性能预期。

若校验通过，系统将数据集标记为合格并自动进入 F1.3 预处理流程；若校验不通过，系统生成详细的质控失败报告，报告中注明异常细胞的编号列表及具体失败原因，提示用户修复后重新上传。

F1.3 数据预处理

数据预处理功能负责将质控通过的原始表达矩阵转化为 ANN 索引引擎可以直接处理的稠密低维特征向量。这一过程是连接原始生物学数据与高性能向量检索的核心桥梁，其处理质量直接决定后续检索结果的生物学准确性。

系统按照固定的标准流水线依次执行以下操作。第一步进行归一化处理，将每个细胞的基因表达计数归一化至总量 10000，消除因测序深度不同导致的细胞间系统偏差。第二步执行对数化变换，即对归一化后的表达值取以自然常数为底的对数加一，以压缩数据动态范围、减弱高表达

基因的主导效应。第三步提取高变基因子集，从数万个基因中筛选出在细胞间表达差异最显著的一组基因，以此降低特征空间的噪声干扰。第四步调用降维算法将高维稀疏矩阵压缩为稠密低维向量，系统支持多种降维方法，包括线性降维方法 PCA 和基于深度学习的非线性方法 VAE 及 scVI，最终生成固定维度的稠密向量。

处理完成后，系统将每个细胞的向量数据(embedding_data)、所用降维算法(reduction_method)、向量维度(dimension)及归一化参数(normalization_params)写入特征向量数据表，为后续查询时的向量对齐提供必要的元信息。

F1.4 数据集查看与删除

数据集查看与删除功能为用户提供对名下已上传数据集的管理能力。用户登录后可在数据管理页面查看当前账号下所有数据集的状态汇总，包括数据集唯一标识(dataset_id)、细胞总数、上传时间、校验状态(通过/失败/处理中)及已生成的特征向量数量等信息。

对于不再需要的数据集，用户可发起删除操作。系统在执行删除前会弹出二次确认提示，明确告知用户该操作不可逆，并将级联清除该数据集下对应的全部特征向量记录及关联的索引数据，以防止产生数据孤岛。删除操作完成后，系统释放该数据集占用的存储配额，并将操作记录写入系统日志。

2. M2 索引构建模块

索引构建模块负责根据输入数据建立检索索引，并完成索引的构建、保存和加载操作，为高效查询提供支持。索引结构的选择与参数配置直接决定系统的检索速度与召回率，是系统核心检索性能的关键所在。

F2.1 索引类型与参数配置

索引类型与参数配置功能为用户提供灵活的索引方案定制能力，允许根据数据规模、内存资源和性能需求选择最合适的索引算法与超参数组合。

在索引算法选择方面，系统支持三类主流 ANN 索引结构。第一类是 Flat 暴力索引，通过对全量向量库进行线性扫描计算精确距离，召回率为 100%，但查询时间随数据量线性增长，适合百万级以下的小规模数据或对精度要求极高的基准对比场景。第二类是 IVF_PQ 倒排量化索引，将向量空间划分为若干个 Voronoi 分桶，查询时仅搜索最近的若干个桶，同时对向量进行乘积量化压缩以大幅降低内存占用，适合千万级以上的大规模数据场景。第三类是 HNSW 分层导航小世界图索引，通过构建多层跳跃图结构实现对数级别的查询复杂度，具备极快的查询速度和较高的召回率，适合对在线查询延迟要求严苛的实时检索服务。

在距离度量方式方面，系统支持三种常用度量：L2 欧氏距离、Cosine 余弦相似度以及 IP 内积。

在参数配置方面，针对 HNSW 索引，用户可配置图的连通度参数 M 和构建时探索宽度 ef_construction；针对 IVF 索引，可配置分桶数 nlist 和量化段数。所有参数最终以 JSON 格式记录至 hyper_params 字段，作为索引的版本化配置信息永久保存。

F2.2 索引构建

索引构建功能依据 F2.1 中的参数配置，对特征向量数据集执行 ANN 索引的实际计算与构建。

用户确认参数配置后提交构建任务，系统调用底层 C++ 索引构建引擎执行密集的数学计算。由于构建过程计算量极大，系统将其设计为后台异步任务，用户提交后可离开页面，系统通过状态轮询接口实时反馈当前进度，`build_status` 字段依次经历 Building、Ready 和 Error 三种状态流转。

在构建过程中，系统持续记录已处理向量数量、当前内存占用及预计剩余时间，方便用户和运维人员实时掌握构建进展。根据第二章的性能约束，千万级规模数据的索引构建时间须控制在 4 小时以内。

索引构建完成后，系统自动触发基准召回率评测，在标准基准数据集上验证该索引的 Top-K 召回率是否达到 95% 的最低要求。评测通过的索引将 `build_status` 更新为 Ready，允许进入后续的保存与加载流程；未通过评测的索引将被标记为不可用状态，系统同时输出性能报告提示用户调整参数后重新构建。

F2.3 索引保存与加载

索引保存与加载功能负责管理索引实例在磁盘与内存之间的生命周期，确保索引在系统重启或服务扩容后仍可快速恢复可用状态。

在保存方面，系统将构建完成的索引实例序列化为二进制文件并持久化写入磁盘，同时在数据库中记录该文件的存储路径 (`index_file_path`)、索引参数及预计内存占用 (`memory_usage`)，确保索引元信息与文件实体始终保持一致。

在加载方面，系统支持热加载机制，即在不重启任何服务的前提下将指定索引从磁盘读入内存，使其立即对检索请求可用。当系统同时维护多个索引时，内存调度策略依据各索引的访问频率和最后访问时间决定卸载优先级，对于长期未被访问的索引自动将其从内存中驱逐以释放资源，需要时再重新加载。加载完成后，系统将对对应索引的状态更新为 Ready，并通知查询检索模块该索引已可用。

F2.4 索引状态监控与版本管理

索引状态监控与版本管理功能为数据库管理人员和检索引擎研发人员提供对所有索引实例的全生命周期管理能力。

在状态监控方面，系统提供统一的索引管理看板，展示当前系统内所有索引的运行状态 (Building / Ready / Error)、内存占用、基准召回率、最后访问时间及关联的数据集信息，帮助管理人员随时掌握索引资源的使用全貌。

在版本管理方面，系统支持索引的增量热更新，即不停止现有检索服务的前提下，将新增细胞的特征向量动态追加至现有索引结构，实现新样本的实时入库，满足第二章任务目标中“动态维护机制”的要求。每次索引更新后，系统自动生成新的版本号并保留历史版本记录，支持管理员在发现新版本质量问题时一键回滚至任意历史版本。新版本索引上线前须经过质量审核，审核通过后方可挂载至线上生产环境替换旧版本，整个切换过程对用户透明无感知。

3. M3 查询检索模块

F3.1 查询输入

查询输入功能为用户提供灵活的查询目标指定方式，支持通过两种途径发起检索请求。

第一种方式是通过细胞编号查询。用户在检索界面输入已存储于系统中的细胞编号 (`cell_id`)，

系统自动从特征向量数据表中查找对应的 `embedding_data`，将其作为本次检索的查询向量。这种方式适合用户希望以数据库中某个已知细胞为参照，寻找与其最相似的其他细胞的场景。

第二种方式是通过原始向量查询。用户直接提交一个浮点数数组作为查询向量，适用于查询目标尚未入库、仅有向量表示的情况（如将刚测序完毕的新细胞向量实时提交检索）。系统接收到原始向量后，首先按照目标索引的归一化参数（`normalization_params`）执行预处理对齐，确保查询向量与索引空间处于同一流形，再校验向量维度是否与目标索引维度一致，维度不一致则返回明确的错误提示信息。

两种方式最终均产生一个经过对齐和校验的标准查询向量，作为后续检索步骤的统一输入。

F3.2 检索参数配置

检索参数配置功能允许用户在执行检索前对检索行为进行精细化定制，既面向普通用户提供简洁的默认配置，也为专业用户提供深度参数调节能力。

系统支持配置以下核心参数。目标索引方面，用户可从当前系统内所有 Ready 状态的索引中选择使用哪一个进行本次检索，不同索引对应不同的算法和数据集版本。返回结果数量方面，用户可设定 Top-K 值（范围 1 至 1000，默认值为 10），决定系统返回多少个最相似的细胞。检索模式方面，用户可在精确检索（召回率 100%，速度较慢）和近似检索（召回率 95%，速度极快）之间选择。查询时超参数方面，面向检索引擎研发人员开放 `ef_search` 等参数的调节入口，允许其在单次查询粒度上微调速度与召回率的平衡，而无需重建索引。元数据过滤条件方面，用户可设置标量过滤约束（如仅在 `tissue_type` 为 Lung 的细胞中进行检索、仅检索来自特定测序平台的细胞），系统在执行向量检索前先按标量条件缩小候选集，实现“标量 + 向量”混合查询，大幅提升检索结果的生物学精准度。

所有配置项均以 JSON 格式记录至 `search_params` 字段，作为本次检索任务的完整参数快照永久保存，确保检索结果可复现。

F3.3 精确最近邻检索

精确最近邻检索功能通过对全量向量库进行暴力扫描，逐一计算查询向量与库中每个细胞向量之间的精确距离，保证 Top-K 结果的 100% 召回率。

系统调用 Flat 索引对向量库执行全量线性扫描，依次计算距离值（L2 欧氏距离、余弦相似度或内积，取决于 F3.2 的配置），将结果按距离升序排列后取前 K 条返回。由于计算量随数据规模线性增长，精确检索主要适用于两类场景：一是数据规模在百万级以下、检索延迟尚在可接受范围内的情况；二是检索引擎研发人员需要以精确结果为基准，评估 ANN 算法在当前数据集上的实际召回率损失时。

检索完成后，系统记录本次查询的端到端执行耗时（`execution_time`）并生成任务记录，将结果传递给可视化展示模块进行后续呈现。

F3.4 近似最近邻检索

近似最近邻检索功能是本系统最核心的高性能检索能力，通过调用预构建的 ANN 索引，在保证召回率不低于 95% 的前提下，将大规模数据的检索响应时间压制在毫秒级别。

系统调用已驻留内存的 ANN 索引实例执行检索。以 HNSW 索引为例，查询过程从图的顶层入口节点出发，在每一层通过贪心策略沿图边向与查询向量更近的节点跳跃，最终在底层精细图中找到近似最近邻候选集，整个过程仅需访问全量数据库中极少一部分节点，从而实现亚线性

时间复杂度的快速检索。

对于配置了元数据过滤条件的请求，系统先依据标量条件对候选向量集进行预过滤，生成满足条件的细胞子集，再在该子集上执行向量相似度检索，保证最终返回的 Top-K 结果在语义和生物学标签两个维度上都符合用户期望。

每次检索完成后，系统生成唯一任务编号 (task_id)，并将完整的检索任务数据写入数据库，包括查询向量快照 (query_vector)、检索参数 (search_params)、匹配结果列表 (result_json)、可视化坐标 (visualization_coords) 及执行耗时 (execution_time)，确保每一次检索结果完整可追溯。根据第二章的性能约束，单次端到端响应时间须不超过 2 秒，Top-K 召回率须不低于 95%，任何不满足上述指标的检索请求均触发系统告警。

F3.5 批量检索

批量检索功能支持用户一次性提交多个查询向量或细胞编号，由系统后台引擎并行处理，适用于基础医学实验人员将成千上万个实验细胞一次性提交比对的高频场景。

用户可通过 Web 界面上传包含多条查询记录的批量文件，也可通过 API 批量接口以程序化方式提交。系统接收到批量请求后，将其拆解为若干子任务并分发至后台工作进程并行执行，充分利用多核计算资源。由于批量任务处理时间较长，系统采用异步任务模式，用户提交后立即获得任务编号，可随时通过任务状态查询接口轮询当前进度。批量任务全部完成后，系统将所有子检索结果汇总为结构化文件 (JSON 或 CSV 格式) 提供下载，并通过系统通知告知用户任务已完成。

F3.6 程序化调用接口

API 接口功能为生物信息学人员提供标准化的程序化调用通道，允许其通过 Python、R 等编程语言将本系统的检索能力作为“插件”无缝集成至自定义的数据分析流水线中，无需通过 Web 图形界面操作。

系统开放以下核心 API 端点：POST /search 接口接收单条检索请求，请求体包含查询向量和检索参数，同步返回 Top-K 匹配结果的 JSON 响应体；POST /batch-search 接口接收批量检索请求，异步处理并返回任务编号；GET /tasks/task_id 接口用于查询指定任务的当前执行状态与最终结果；GET /indexes 接口返回当前系统中所有 Ready 状态索引的列表及其基本参数信息。

所有接口严格遵循 RESTful 设计规范，请求须在 HTTP Header 中携带合法的 API Token (由 F5.2 用户登录后签发)，数据交换格式统一采用 JSON，HTTP 状态码规范使用。系统提供完整的 API 接口文档，供生物信息学人员进行二次开发与个性化流水线定制。

4. M4 可视化展示模块

可视化展示模块负责将检索结果以直观的形式展示给用户，是连接底层技术能力与用户感知价值的最终桥梁。本模块的核心目标是让不具备编程背景的临床诊断人员和基础医学实验人员也能通过直观的图表理解检索结果的生物学意义。

F4.1 Top-K 检索结果列表展示

Top-K 检索结果列表展示功能以结构化列表形式呈现系统返回的最相似细胞集合，并为每条结果附带丰富的生物学元数据信息，帮助用户快速理解匹配结果的生物学含义。

系统将 Top-K 结果渲染为可交互的数据表格，每一行对应一个匹配细胞，展示的信息包括：细胞唯一编号 (cell_id)、与查询细胞的相似度分值或距离值（按升序排列，距离越小相似度越高）、专家标注的细胞类型标签 (cell_type_label)、组织来源 (tissue_type)、供体编号 (donor_id) 以及测序平台信息。用户可在列表上方设置筛选条件，按细胞类型或组织来源快速过滤结果，也可点击任意一行记录查看该细胞的完整基因表达详情弹窗，包括其高表达基因列表和扩展的实验元数据信息。

F4.2 UMAP/t-SNE 降维散点图可视化

UMAP/t-SNE 降维散点图可视化功能是本模块最核心的可视化能力，通过在二维空间中展示细胞间的空间分布关系，帮助用户从全局视角理解查询细胞在整个细胞图谱中的位置与周边环境。

系统采用 WebGL 硬件加速渲染技术在前端绘制高维降维散点图，每个散点代表数据库中的一个细胞，其在二维平面上的坐标由第四章检索任务数据中的 visualization_coords 字段决定。为应对百万级散点的渲染压力，系统采用分层渐进加载策略，优先高精度渲染查询细胞及其 Top-K 近邻所在区域，背景参考图谱则通过降采样逐步加载，以此在渲染性能与视觉完整性之间取得平衡，防止浏览器因一次性渲染过多 DOM 节点而崩溃。

在视觉设计上，查询细胞以显眼的高亮颜色（如红色五角星）标注于图中，Top-K 匹配结果以另一种差异色（如橙色实心圆）集中标注，其余背景参考细胞以灰色或按细胞类型着色的散点展示。系统支持丰富的用户交互操作，包括鼠标滚轮缩放、拖拽平移、框选区域（被框选的细胞会在结果列表中同步高亮）以及悬浮查看单个细胞的元数据详情。用户还可通过顶部色彩切换控件，在按细胞类型着色和按组织来源着色之间一键切换，从不同维度观察细胞的聚集规律。对于发现的异常细胞亚群，用户可框选对应区域后将其单独导出为子数据集，供进一步分析。

F4.3 性能指标展示

性能指标展示功能为不同层次的用户提供本次检索及系统整体运行状态的量化数据，既服务于普通用户对单次查询结果的理解，也服务于检索引擎研发人员的系统调优工作。

对于普通用户，系统在检索结果页面显示本次查询的端到端响应时间，以及当前所用索引的基准召回率指标，帮助用户对结果的可信程度有直观的量化认知。

对于检索引擎研发人员，系统额外提供底层性能监控看板，实时展示系统级别的运行指标，包括查询延迟的百分位分布、当前每秒处理查询数、各索引实例的内存驻留大小以及服务器的 CPU 和内存整体使用率。所有指标均以折线图或仪表盘形式动态更新，并支持历史趋势查看，帮助研发人员定位性能瓶颈、验证参数调优效果。

F4.4 诊断报告导出

诊断报告导出功能将本次检索的结果、可视化图表及统计分析整合为一份结构完整的诊断辅助报告，支持导出为 PDF 格式，主要面向临床医学诊断人员的工作场景。

系统首先对 Top-K 匹配结果执行细胞类型投票统计，汇总所有匹配细胞的类型标签分布，生成细胞类型占比饼图，使临床人员能够快速把握查询细胞最可能的生物学身份。随后，系统将本次检索的完整参数配置、匹配结果摘要表格、细胞类型分布图表以及 UMAP 散点图截图自动排版整合，生成格式规范的 PDF 报告。报告结构清晰，语言面向临床非技术用户设计，不含晦涩的算法细节，确保临床诊断人员可以直接将其保存至患者档案或提交至临床讨论。

5. M5 用户信息模块

用户信息模块是整个系统的安全入口和权限中枢，负责用户的注册、登录、身份验证与权限管控。用户可以通过账号密码注册登录系统并查看可视化系统，管理员可以进行用户管理等。

F5.1 用户注册

用户注册功能为新用户提供创建系统账号的入口，允许用户填写基本身份信息并选择对应的角色类型，完成账号的初始化创建。

用户在注册页面依次填写用户名(username)、登录密码、所属机构或实验室名称(institution)以及角色类型(role_type, 从临床医学诊断人员、基础医学实验人员、生物信息学人员、搜索引擎研发人员、数据库管理人员及系统运维人员中选择)。系统首先校验用户名的唯一性，若已存在同名账号则返回提示并要求更换。密码经过加盐哈希处理后以 password_hash 字段存储于数据库，系统任何位置均不保存明文密码。注册成功后，系统为该用户生成唯一标识(user_id)、记录账号创建时间戳(created_at)，并根据角色类型分配对应的默认存储配额(storage_quota)，最后将用户引导至登录页面完成注册流程。

F5.2 用户登录与身份验证

用户登录与身份验证功能负责在用户进入系统时核验其身份合法性，并根据其角色类型将用户引导至对应的功能工作台。

用户在登录页面输入用户名和密码后，系统从数据库中查询对应账号的 password_hash，将其与输入密码的哈希值进行比对。验证通过后，系统签发会话 Token 并设置有效期，后续所有功能请求均通过 Token 验证身份，无需重复登录。为防止暴力破解攻击，系统设置连续登录失败超过 3 次即触发账号临时锁定机制，锁定期间拒绝来自该账号的全部登录请求。

登录成功后，系统读取用户的 role_type 字段，依据六类角色将用户路由至对应的专属工作台：临床医学诊断人员进入检索诊断链路、基础医学实验人员进入批量查询链路、生物信息学人员进入 API 访问链路、搜索引擎研发人员进入性能调优链路、数据库管理人员进入数据建库链路、系统运维人员进入硬件监控链路，确保每类用户进入系统后即可直接看到与其职责对应的核心功能界面。

F5.3 角色权限控制

角色权限控制功能在用户登录后的每一次功能访问中持续生效，根据用户角色动态控制其可访问的功能范围，实现功能边界管理与多租户数据隔离。

在功能访问控制方面，系统依据 role_type 动态渲染各用户可见的功能菜单，对无权限的模块在界面上隐藏或置灰，防止误操作。例如，临床医学诊断人员的界面不显示索引构建后台入口，普通研究人员的界面不显示用户管理功能。对于绕过界面直接发起的非授权 API 请求，系统后端统一返回 403 Forbidden 响应，确保权限校验不依赖前端界面的显隐逻辑。

在数据隔离方面，系统通过 user_id 实现严格的多租户隔离，每个用户只能查看和操作自己上传的数据集、构建的索引及发起的检索任务，无法通过任何途径访问或通过统计学方法推测其他用户的私有数据。仅被显式标记为“公共数据库”的数据集对全体用户开放检索。所有权限校验结果及敏感操作均写入系统操作日志，支持事后的安全审计与合规核查。

F5.4 用户管理

用户管理功能提供仅限系统管理员访问的后台用户管理界面，支持对全体系统用户账号进

行查看、修改、禁用和删除等操作，是系统多租户运营管理的核心工具。

管理员登录后进入用户管理中心，可查看系统内所有注册用户的完整列表，并支持按用户名、所属机构、角色类型及注册时间进行多维度筛选查询。在具体管理操作方面，管理员可修改指定用户的角色类型及存储配额，以适应用户职责变化或资源调整的需求；可重置指定用户的密码，应对用户忘记密码的情况；可对违规账号执行禁用操作，禁用后该账号无法登录但其历史数据完整保留，支持后续恢复；可对不再使用的账号执行删除操作，删除时系统级联清除该用户名下的全部私有数据集、索引及检索任务记录，彻底释放存储资源。所有管理操作均强制写入不可篡改的审计日志，记录操作人身份、操作时间及操作内容，确保管理行为全程可追溯、可审计。

六、性能/非功能需求

本系统属于面向课程期末工程系统，其性能与非功能需求主要面向单机部署、教学实验数据集和小组演示场景进行设计，不以生产环境下的大规模在线服务作为直接验收标准。在此前提下，系统需要具备相适应的准确性、响应能力和工程可用性。

（一）准确性

系统采用近似最近邻检索方法，允许检索结果与精确最近邻结果之间存在有限偏差，但该偏差必须控制在合理范围内。具体要求如下：

- **检索结果准确：**在固定测试数据集、固定索引参数和固定过滤条件下，系统返回的 Top-K 检索结果应与精确检索结果保持较高一致性。对于课程实验所采用的代表性数据集，召回率宜达到 90% 以上，经参数调优后应尽量接近 95%。
- **元数据关联正确：**系统返回的细胞编号、相似度得分、数据集来源和细胞类型标签等信息应与底层向量索引及元数据记录严格对应，避免出现错配、重复返回、漏回或标签回溯错误。
- **输入校验完整：**系统应对向量维度、数据格式、距离度量方式、索引版本等进行一致性校验，防止因输入异常、参数不匹配或索引状态错误导致检索结果失真。
- **结果具有可重复性：**对于同一查询向量、同一索引和同一参数设置，系统应能稳定返回一致或统计意义上一致的结果，以保证实验结果的可解释性与可复现性。

（二）及时性

系统应满足课程演示和交互式分析场景下的时效要求，既能保证基本查询速度，也能为长时任务提供明确反馈。具体要求如下：

- **查询响应及时：**在单机实验环境、十万级至百万级向量数据规模下，普通 Top-K 查询的平均响应时间宜控制在 1 秒以内；在附加元数据过滤或可视化结果联动的情况下，端到端响应时间一般不应超过 2 秒。
- **界面交互流畅：**用户在执行数据上传、参数提交、结果筛选和页面切换等常见操作时，系统应保持较好的交互流畅性，避免长时间无响应或频繁阻塞。
- **后台任务可跟踪：**对于数据导入、索引构建、批量检索等耗时操作，系统应提供任务状态、执行进度和异常提示，避免用户无法判断任务执行情况。
- **结果返回及时：**对于查询结果展示和结果导出操作，系统应在合理时间内完成处理，并能够在必要时采用异步方式返回结果下载链接或任务完成通知。

(三) 可扩充性

考虑到单细胞数据规模和算法方案可能持续变化，系统应具备一定的扩展能力。具体要求如下：

- **模块边界清晰：**系统应将数据导入、预处理、特征向量管理、索引构建、检索服务、结果展示和用户管理等功能模块相对解耦，降低后续修改对整体系统的影响。
- **算法方案可替换：**系统应支持后续替换或扩展不同的 ANN 索引结构与距离度量方式，例如在图索引、倒排索引或量化方案之间进行调整，而无需重构整体业务流程。
- **数据格式可扩展：**系统在支持当前约定输入格式的基础上，应为后续接入新的单细胞数据格式、向量表示方式及元数据字段预留接口。
- **体系结构具备演进空间：**课程项目阶段可以单机实现为主，但系统架构上应为后续接入增量更新、更大规模数据集和分布式部署保留扩展空间。

(四) 易用性

本系统面向基础医学实验人员、生物信息学人员和课程项目组成员，界面与交互设计应兼顾可学习性与操作效率。具体要求如下：

- **核心流程简洁：**用户应能够在较少步骤内完成数据上传、参数设置、索引构建、相似检索和结果查看等核心操作，避免过多重复配置。
- **参数设置明确：**对于 Top-K、距离度量方式、查询数据集、过滤条件等关键参数，系统应提供必要说明、合理默认值及输入范围限制，降低误操作概率。
- **异常提示清晰：**当出现文件格式错误、维度不一致、索引未就绪、权限不足或查询失败等情况时，系统应给出明确、易于理解的错误提示和处理建议。
- **结果展示直观：**系统应能够以列表、统计信息和可视化图形等方式展示检索结果，帮助用户快速理解检索命中情况及其生物学含义。

(五) 易维护性

系统应具备较好的可读性、可调试性和协作开发友好性，便于课程项目后续迭代。具体要求如下：

- **代码组织规范：**系统应遵循统一的命名规则、目录结构和编码风格，核心模块之间接口清晰，便于小组成员分工开发、联调与修改。
- **日志与异常信息完整：**系统应记录必要的运行日志、错误日志和关键操作日志，用于定位数据导入失败、索引构建异常、检索超时及接口调用错误等问题。
- **配置管理清晰：**系统中的数据库连接、索引参数、路径配置和服务端口等信息应尽量集中管理，避免硬编码带来的维护困难。

- **说明文档基本齐全：**系统应配备基本的开发说明、部署说明和测试说明，以支持环境复现、问题定位和后续功能扩展。

(六) 标准性

系统在文档、接口、数据格式和开发过程等方面应保持统一规范。具体要求如下：

- **文档术语统一：**需求分析、概要设计、测试说明等文档中的术语、对象命名、接口字段和性能指标应保持一致，避免同一概念在不同章节中出现歧义。
- **数据格式规范：**系统输入输出应尽量采用常见且便于处理的数据格式，如单细胞数据文件支持 .h5ad、.mtx 等常见格式，接口数据交换统一采用 UTF-8 编码的 JSON。
- **接口设计规范：**系统采用前后端分离架构，接口设计应尽量遵循 RESTful 风格，并合理使用统一的请求参数命名方式、返回结构和状态码。
- **版本与来源可追溯：**对于导入的数据集、构建的索引和实验中使用的关键参数，系统应保留必要的版本信息和来源说明，便于结果追踪与实验复现。

(七) 先进性

系统应在保证可实现、可验证和可维护的前提下，合理体现技术先进性。具体要求如下：

- **采用成熟的 ANN 技术路线：**系统应优先选用当前较为成熟的高维向量检索技术，如图索引、倒排索引、向量压缩或向量与元数据联合检索等方案，以体现对单细胞高维检索问题的针对性。
- **体现领域结合特点：**系统设计应能够结合单细胞数据高维、稀疏、规模大等特点，而不是简单套用通用查询系统思路。
- **兼顾演示性与工程性：**拒绝盲目堆砌复杂技术，而应体现为在课程项目可完成的范围内，合理展示 ANN 相较于传统线性扫描在效率上的优势。
- **为后续演进提供基础：**系统应为增量更新、更大规模数据处理、性能优化和更丰富的可视化分析保留进一步提升的空间。

七、 系统运行要求

(一) 硬件配置要求

为保证系统在课程项目开发、测试与演示阶段能够稳定运行，硬件环境应以常见实验室工作站或个人计算机可获得的配置为主，以单机部署为基本形态。具体要求如下：

1. 开发与部署主机

- **最低配置：**64 位处理器，4 核 CPU，8GB 内存，50GB 以上可用磁盘空间。该配置可支持系统基础开发、小规模单细胞数据导入和基本检索功能演示。
- **推荐配置：**64 位处理器，8 核及以上 CPU，16GB-32GB 内存，100GB 以上 SSD 存储空间。该配置更适合开展中等规模数据集的索引构建、性能测试和可视化展示。
- **处理器要求：**CPU 应支持多线程并行计算，以满足向量预处理、索引构建和查询服务的基本性能需求。
- **存储要求：**建议优先使用 SSD，以提高数据读写和索引加载速度；磁盘空间除保存程序本体外，还应预留用于数据文件、索引文件、日志和中间结果。
- **GPU 要求：**系统核心功能不强制依赖 GPU。若后续需要进行大规模嵌入生成、模型训练或更复杂的降维计算，可根据条件选配 GPU 设备，但不作为课程项目验收的必要条件。

2. 客户端与展示终端

- 普通个人计算机即可访问系统，建议具备 4GB 及以上内存、1366×768 及以上分辨率显示能力。
- 系统包含可视化展示模块，客户端应具备基本图形渲染能力，以保证散点图、降维结果图和统计图表的正常显示。
- 用于演示或答辩的终端应具备稳定网络连接，避免因浏览器卡顿或网络中断影响系统展示效果。

3. 网络与其他条件

- 系统在校园网、实验室局域网或普通互联网环境下均应能够正常运行；若采用前后端分离部署方式，服务端与客户端之间应保持稳定的 HTTPS 通信环境。
- 具备基本的数据备份条件，例如外接存储设备或独立目录备份机制，用于保存原始数据、索引文件和实验结果。

(二) 软件配置要求

系统的软件环境应满足开发、部署、调试和展示的基本要求，并兼顾课程项目的实现难度与环境可复现性。具体要求如下：

1. 操作系统

- 服务端需要部署在 Windows 10/11 或 Ubuntu 20.04 及以上版本的 64 位操作系统上。
- 客户端无需依赖特定操作系统，应能够在常见桌面环境下通过浏览器访问系统。

2. 开发与运行环境

- 后端应当采用 Python 3.10 及以上版本作为主要开发与运行环境，用于实现数据处理、任务调度、接口服务和实验验证。
- 若底层检索模块采用高性能原生库封装，则开发环境应支持 C++17 及以上标准，以满足核心检索算法的实现和集成需求。
- 使用虚拟环境或 Conda 管理项目依赖，减少小组成员之间的环境差异问题。

3. 算法与数据处理依赖

- 系统应安装必要的数据处理相关依赖库，如 NumPy、Pandas、scikit-learn、AnnData、h5py 等，以支持单细胞数据读取、预处理和特征表示转换。
- 系统应配备至少一种可用于近似最近邻检索的算法库，如 FAISS、HNSWLIB 或同类工具，以支持向量索引构建和查询实验。
- 若系统包含降维与可视化处理流程，还应具备 PCA、UMAP、t-SNE 等相关计算依赖环境。

4. 数据存储与服务组件

- 系统应具备关系型数据库环境，用于存储用户信息、任务记录、细胞元数据和索引描述信息。课程项目实现阶段可根据复杂度选择 SQLite 等轻量级数据库；若需要更强的结构化查询能力，推荐使用 PostgreSQL。
- 系统提供 Web 服务接口，采用适合课程项目实现的轻量级服务框架，如 Flask、FastAPI 或 Django 等，并根据实际情况选择其一实现。
- 系统内部文本、配置和接口数据交换应统一采用 UTF-8 编码，避免中文字段在不同环境下出现乱码。

5. 前端与浏览器环境

- 客户端应使用支持 HTML5、JavaScript 和 WebGL 的现代浏览器，如 Chrome、Edge 或 Firefox，以保证页面交互和可视化功能正常运行。
- 系统采用前后端分离方式，前端页面需要通过 HTTPS 协议稳定访问后端接口，并正确解析 JSON 格式返回结果。

6. 开发协作与环境复现

- 项目开发过程中应当使用 Git 进行版本管理，以支持小组成员协同开发、代码回溯和阶段性成果管理。
- 保留依赖清单、环境说明和启动脚本，便于在课程验收、答辩演示和后续修改中快速复现系统运行环境。